

# SP3CTRUM

Desafio Quant AI 2025 Itaú Asset



Asset

## Explicação do nome

SP3CTRUM é o nome do nosso robô e representa exatamente a ideia central do fundo: enxergar o mercado como um espectro amplo de possibilidades. Derivado da palavra em inglês *spectrum*, que significa espectro, o nome remete a uma faixa contínua de oportunidades, riscos, sinais e regimes de mercado. A troca da letra “e” pelo número 3 não é apenas estética: o “3” simboliza diretamente as três estratégias quantitativas que compõem o coração do fundo, reforçando na própria marca a ideia de diversificação e complementaridade entre os modelos.

## Explicação lógica da estratégia

Nosso robô SP3CTRUM foi desenhado para explorar, de forma equilibrada, três grandes frentes do mercado financeiro e para cada uma desenvolvemos uma estratégia. As três estratégias recebem alocação igual de capital, visando identificar comportamentos de diferentes agentes do mercado e conseguir retornos complementares.

Na primeira, voltada a pessoas físicas, adotamos uma estratégia de *dividend run-up*, comprando ações alguns dias antes do pagamento de dividendos para capturar a valorização gerada pelo aumento de demanda.

Na segunda, focada em investidores sofisticados, monitoramos o short interest das ações brasileiras e montamos posições compradas naquelas com menor nível de venda a descoberto, sinalizando menor ceticismo do mercado e potencial de alta.

Na terceira, usamos um grupo de quatro agentes de IA que simulam um comitê de investimentos profissional, integrados via Agno e ChatGPT, que analisam empresas da bolsa brasileira sob perspectivas diferentes e que convergem para recomendações de posição.

## Classe de ativos

Ações

## Universo Investimento

As 30 ações mais líquidas do Ibovespa de acordo com o ChatGPT (Out-2025)

## Frequência da estratégia

Rebalanceamento mensal

## Benchmark

CDI





# SP3CTRUM

O SP3CTRUM busca explorar o comportamento de diferentes agentes de mercado, sendo eles, as **pessoas físicas, investidores sofisticados, e comitês de investimento profissionais**



**30 ações do IBOVESPA**  
Escolhidas pela AI



**Análise do histórico de dividendos**




**Análise do short-interest das empresas**




**Uso de agentes LLM para diagnostico de empresas**




**Previsão do próximo pagamento**



**Divisão em percentis de SIR**




**Análise fundamentalista de empresas da bolsa**



**Compra próximo ao pagamento previsto**



**Compra dos ativos no percentil otimizado**



**Uso de poder computacional para a previsao de mercado**

**Divisão igual do capital para gerar retornos**

# SP3CTRUM

## Desenvolvimento do trabalho

### Ideia de investimento

O mercado acionário é formado por agentes heterogêneos que processam informação, tomam risco e executam ordens de modo distinto. A nossa tese é capturar três fontes de retorno economicamente diferentes no Brasil, alinhadas a perfis de agentes também distintos: (i) pressão de fluxo de pessoas físicas em eventos de proventos; (ii) posicionamento/convicção de investidores sofisticados via short interest; (iii) consenso disciplinado de análise (fundamentalista e técnica) por meio de um comitê algorítmico com LLMs que emula uma casa de investimentos. Ao combinar motores de retorno com comportamentos, janelas e dados diferentes, buscamos reduzir a correlação entre “alphas” e aumentar a robustez a mudanças de regime. Dividimos o capital igualmente em três estratégias:

1. **Short-interest:** com base em Boehmer, Huszar e Jordan (2010) [4], níveis baixos de short interest indicam menor pressão vendedora e, em média, maior otimismo por parte de agentes sofisticados. Seleccionamos, no nosso universo, as ações com menores níveis de short interest.
2. **Dividend run-up:** a literatura [1, 2, 3] documenta demanda excessiva por “ações de dividendo”, gerando pressão de preço antes do evento e ignorando perdas de capital posteriores. No Brasil, parte relevante desse movimento parece partir de pessoas físicas. Usando o histórico de proventos, projetamos meses com alta probabilidade de distribuição e compramos alguns dias úteis antes da Data Com, encerrando na data prevista.
3. **Trading agents:** inspirado em Wang et al. (2023) [5], implementamos um sistema multiagente baseado em LLMs: *Analyst* (fundamentalista), *Bull* (técnico pró-tendência), *Bear* (técnico contracorrente/risco) e *Senior* (alocação/gestão). Cada um produz análise autônoma e o *Senior* consolida as visões em decisão de investimento. O arranjo replica o funcionamento de um comitê de investimentos profissional, porém inteiramente composto por LLMs, mais especificamente, AI agents.

### Universo e Dados

#### Universo

Trabalhamos com ações por familiaridade e disponibilidade de dados. Inicialmente pretendíamos usar todo o Ibovespa, mas a estratégia de *Trading Agents* consome intensamente a API do ChatGPT, elevando o tempo de processamento por papel. Rodar a estratégia em todo o índice poderia levar mais de uma semana de execução. Para viabilizar essa estratégia, reduzimos o universo para **30 ações entre as mais líquidas da B3** de acordo com o próprio ChatGPT. Esse recorte preserva negociabilidade, reduz fricções operacionais e trouxe o tempo total de execução para cerca de 19 horas, apesar de isso ainda ser muito tempo.

#### Dados

Para as três estratégias utilizamos: preço de fechamento ajustado, quantidade de ações alugadas e *shares outstanding*, além de Data Com de dividendos. A fonte primária foi a *Econômica* (acesso institucional), com séries mensais. Por se tratar de nomes líquidos, a necessidade de limpeza foi mínima e praticamente não houve dados faltantes. Sempre que aplicável, calculamos indicadores com janelas e informações disponíveis apenas até  $t - 1$ .

### Origem da ideia

Começamos com a meta de empregar LLMs, em linha com o tema do desafio. Por orientação do mentor, investigamos também short interest e dividendos por serem frentes recentes e promissoras no Brasil. Embora pareçam abordagens distintas, elas refletem “escolas” diferentes de decisão: leitura de posicionamento (short interest), viés/comportamento (corrida por proventos) e análise



estruturada por comitê (LLMs). Ao integrar esses perfis no **SP3CTRUM**, passamos a combinar fontes de retorno potencialmente complementares, reduzindo a dependência de qualquer componente isolado. Daí a proposta de dividir o capital em três blocos operando em paralelo, com a expectativa de maior resiliência a regimes de mercado diferentes.

### Regras de investimento

As três estratégias usam **rebalanceamento mensal**. Essa frequência reduz custos de transação em um arranjo com múltiplos sinais e limita a carga computacional do *Trading Agents*. No *Dividend run-up*, janelas muito curtas tornam a previsão de eventos pouco confiável; a escala mensal é mais adequada. Custos de transação de 0,1% foram considerados uniformemente no backtest.

### Short-interest

Medimos *short interest* diariamente a partir de ações alugadas e *outstanding*. A literatura para o mercado americano sugere desempenho superior no extremo de menor short interest [4]. Como estamos em outro mercado, evitamos fixar um único ponto de corte. Definimos um **percentil adaptativo por ano**: em cada ano, testamos percentis no período anterior e adotamos, para o ano corrente, aquele que obteve o maior retorno no ano imediatamente anterior. Em cada mês, compramos ações posicionadas entre os menores níveis de short interest de acordo com o percentil vigente e encerramos ao fim do mês.

- **Cuidados no backtest**: o parâmetro otimizado é apenas o percentil e é escolhido sempre usando *dados do ano anterior*, mitigando *look-ahead*. A *Econômica* fornece as séries diárias de alugadas e *outstanding*, o que dispensa defasagens artificiais.
- **Limitações**: a escolha por “melhor percentil do ano anterior” pode ser simplista e sensível a ruído. Abordagens como *cross-validation* por janela deslizante ou modelos de *forecast* para o percentil ótimo podem estabilizar o parâmetro.

### Dividend run-up

Para capturar a “corrida” por proventos, identificamos, nos últimos três anos, padrões de sazonalidade (trimestral, semestral ou anual) por papel a partir dos intervalos entre eventos. Quando há padrão, projetamos a próxima Data Com aproximada e geramos o sinal: posição comprada  $N$  dias úteis antes e encerramento na data projetada. A alocação considera a possibilidade de manter o capital em CDI quando não há sinal robusto. O rebalanceamento mensal reavalia sazonalidade, atualiza projeções e ajusta pesos com base em um *score* (menor volatilidade relativa). O  $N$  foi escolhido como aquele que deu maior retorno utilizando essa estratégia entre 2019-2022, a saber, 11 dias. Destaca-se ainda que esse valor está alinhado à média de antecedência de anúncio de dividendos do mercado americano [2].

- **Cuidados no backtest**: todas as projeções e filtros usam apenas informação disponível até  $t - 1$ , com janelas truncadas no tempo.
- **Limitações**: a sazonalidade de proventos no Brasil é menos regular, reduzindo o número de sinais. A escolha de  $N$  e do critério de sazonalidade pode ser aprimorada (busca em grade, validação por janela, ou modelos probabilísticos de evento).

### Trading Agents

Nós desenvolvemos uma estratégia multi-agente inteiramente baseada em LLMs para análise e tomada de decisão nas ações brasileiras selecionadas. A arquitetura reúne quatro agentes especializados — Analyst (fundamentalista), Bull (técnico com viés pró-tendência), Bear (técnico com viés contracorrente/risco) e Senior (gestão de portfólio) — que operam de forma hierárquica e colaborativa, espelhando o funcionamento de um comitê de investimentos da vida real. Em cada ciclo, os agentes recebem apenas informações disponíveis até  $t-1$  (preços ajustados, volume, métricas de volatilidade e correlações, fatos relevantes, entre outros), evitando data leak e também evitando certos vieses. O Analyst sintetiza fundamentos (lucros, guidance, múltiplos) e produz

um score de valor/qualidade com horizonte sugerido; o Bull avalia tendência, força relativa setorial e rompimentos para gerar um score pró-continuidade; o Bear estima riscos de reversão e sobre-compra/sobre venda, formando um score contracíclico; por fim, o Senior integra as pontuações por meio de regra de consenso ponderada por confiança e acurácia histórica por setor, traduzindo o resultado em sinal Long/Short e peso por ativo sob restrições de risco.

- **Cuidados no backtest:** A plataforma utilizada para operacionalizar essa orquestração, a API Agno, realiza o corte temporal no acesso aos dados que fornecemos ao modelo de modo que não há look-ahead bias no conteúdo que nós fornecemos. Existe ainda, contudo, o risco inerente de usar LLMs em backtests que é eles terem sido treinados com dados futuros. No modelo que utilizamos, gpt-4o-mini, ele foi treinado até outubro de 2023.
- **Limitações:** Não utilizamos as versões mais recentes e poderosas do ChatGPT em razão deles terem sido treinados no período do backtest, logo possivelmente teríamos melhor performance com um modelo mais atual. Além disso, poderíamos ter expandido a base de dados de acesso a dados de sentimento de mercado, como fez o paper em que nos baseamos [5], mas a complexidade tornou inviável.

### Formação do SP3CTRUM

O portfólio **SP3CTRUM** aloca 1/3 do capital em cada estratégia e executa os sinais de forma independente, com rebalanceamento mensal. A agregação simples facilita a leitura do ganho de diversificação entre motores de retorno e serve de base neutra para comparações futuras com esquemas de *ensemble* dinâmicos.

### Resultados

Avaliamos risco e retorno de cada estratégia e do agregado, com custos de 0,1% por operação. O período do backtest vai de 01/09/2023 (formação inicial dos portfólios) a 01/08/2025. O objetivo principal é verificar se a combinação reduz volatilidade e *drawdown* mantendo retorno acima do CDI.

Antes, um esclarecimento importante: a **estratégia de Dividend run-up** apresentou métricas excelentes, mas com poucas aberturas de posição e forte contribuição do **carregamento em CDI** nos períodos sem sinal. Ou seja, a consistência dessa perna advém em boa parte do CDI, enquanto os poucos trades efetivos explicam os picos de desempenho evidenciados na Figura 1. Essa característica deve ser considerada na leitura dos resultados agregados.

A Tabela 1 resume o desempenho. Em termos de retorno anualizado, *Div.* ficou muito acima do CDI; *Short-int.* e *Trading a.* entregaram retorno superior ao CDI com volatilidade mais alta, como esperado para estratégias direcionais. O agregado **SP3CTRUM** preservou *excesso de retorno* e exibiu **volatilidade menor** que as pernas isoladas, elevando *Sharpe*, *Sortino* e *Calmar* frente a *Short-int.* e *Trading a.*. O **Max Drawdown** do portfólio foi materialmente inferior ao das estratégias individuais, sinal de **diversificação efetiva**.

A Figura 1 mostra a trajetória acumulada. Em 2024, o *Short-int.* teve fase negativa e o *Trading a.* ficou praticamente de lado. Ainda assim, o *Dividend run-up* sustentou o resultado agregado positivo. Essa desincronização é consistente com a baixa correlação entre as pernas. A Tabela 2 reporta correlações par-a-par baixas entre *Short-int.*, *Div.* e *Trading a.*, todas próximas de zero em valor absoluto. É esse *desalinhamento de motores* que explica por que o SP3CTRUM melhora razão retorno/risco mesmo sem cada perna vencer isoladamente em todos os subperíodos.

No geral, os resultados sustentam a tese: **combinar motores de retorno heterogêneos** entregou melhor equilíbrio risco/retorno do que operar cada um isoladamente. Ainda assim, há espaço para robustez extra via escolha mais sistemática de parâmetros e maior diversidade informacional no comitê LLM.

### Conclusão

Nossa **tese principal** foi clara desde o início: capturar três fontes de retorno distintas, cada uma ligada a um tipo de agente no mercado brasileiro, e combiná-las para reduzir correlação e tornar o portfólio mais estável. Esses três blocos são: pressão de fluxo de pessoas físicas em eventos de proventos, posicionamento de investidores sofisticados via short interest e um comitê

algorítmico com LLMs que emula a análise estruturada de casas de investimento. Os resultados do **SP3CTRUM** são coerentes com essa tese. O portfólio manteve retorno acima do CDI com **volatilidade e drawdown menores** do que operar cada perna isoladamente, e as correlações baixas entre as estratégias explicam por que a combinação funcionou mesmo quando uma delas passou por fase pior.

Alguns pontos exigem cuidado na leitura. O *Dividend run-up* operou pouco e, nos períodos sem sinal, ficou ancorado no CDI. Isso ajuda o agregado, mas não deve ser interpretado como alfa recorrente. O *Short-int.* depende da escolha de percentil, que pode mudar de um ano para outro. O *Trading agents* mostrou potencial com um setup enxuto, o que sugere ganhos ao ampliar o conjunto de dados e refinar a consolidação das recomendações.

Próximos passos objetivos, alinhados à nossa tese:

- **Parâmetros mais sólidos:** substituir “melhor do ano anterior” por validação em janela deslizando no *Short-int.* e escolha sistemática de  $N$  no *Dividend run-up*.
- **Mais informação para o comitê:** incorporar notícias, sentimento e métricas setoriais para decisões dos agentes LLM, com monitoramento de qualidade ao longo do tempo.
- **Agregação adaptativa:** testar pesos dinâmicos simples no lugar de  $1/3-1/3-1/3$ , limitando contribuição de risco de cada perna e reduzindo exposição quando houver aumento de correlação.

Em resumo, a evidência empírica favorece a **tese de agentes heterogêneos**: combinar comportamentos diferentes gerou um portfólio mais equilibrado entre retorno e risco. Com pequenos ajustes de processo e dados, a expectativa é de maior robustez fora da amostra mantendo a simplicidade exigida em competição.

# Tabelas e Gráficos

Table 1: Summary of Backtest Results

Metric	Short-int.	Div.	Trading a.	SP3CTRUM	CDI
CAGR (%)	13.26	22.78	13.52	17.38	11.96
Excess vs CDI (pp)	2.94	25.41	3.52	12.43	-
Volatility (ann., %)	17.36	10.20	18.94	8.80	0.45
Sharpe	0.15	0.95	0.16	0.58	-
Sortino	0.24	4.76	0.27	0.99	-
Max Drawdown (%)	-16.62	-1.65	-11.06	-5.30	-
Calmar	0.80	13.81	1.22	3.26	-

Notas: CAGR, volatilidade e demais métricas anualizadas; Sharpe com CDI como taxa livre de risco. Calmar = CAGR / —MaxDD—.

Table 2: Pairwise Correlations (Lower Triangle)

	Short-int.	Div.	Trading a.	SP3CTRUM	CDI
Short-int.	1.00				
Div.	-0.08	1.00			
Trading a.	-0.06	0.02	1.00		
SP3CTRUM	0.60	0.30	0.68	1.00	
CDI	0.33	-0.24	-0.10	0.05	1.00

Notas: exibido apenas o triângulo inferior; diagonal = 1.00.




Figure 1: Cumulative return comparison of the strategies.

## Uso de IA Generativa

### ChatGPT, Gemini e Claude

Ao longo do desenvolvimento da estratégia, o ChatGPT e o Gemini foram empregados em praticamente todas as etapas, além de participarem diretamente da geração de sinais. No processo inicial de brainstorming e pesquisa, a ferramenta de busca integrada do ChatGPT foi essencial para identificar artigos acadêmicos relevantes relacionados ao uso de LLMs e abordagens inovadoras em mercados financeiros.

Na fase de construção e teste da estratégia, os modelos foram fundamentais na elaboração do código utilizado para gerar sinais de entrada e saída. Nenhum membro do time possuía conhecimento avançado de programação, portanto, o suporte desses LLMs foi determinante para estruturar e implementar o backtest de forma eficiente.

Por fim, utilizamos LLMs para aprimorar a redação do relatório final, escrevemos uma versão de base e pedimos aprimoramentos, garantindo maior coesão e fluidez na apresentação dos resultados e justificativas metodológicas.

No que se refere especificamente à geração de sinais, conforme detalhado na seção de desenvolvimento do trabalho, o ChatGPT, via API, desempenhou papel central na construção estratégia dos Trading agents. Toda a análise de risco, leitura de contexto de mercado e orquestração das decisões simuladas foi conduzida pelo modelo, reproduzindo o comportamento de uma “firma” fictícia inteiramente composta por LLMs.

### NotebookLM

O NotebookLM teve papel complementar, mas relevante. Por sua capacidade de operar exclusivamente com as fontes fornecidas, ele foi utilizado para auxiliar na compreensão aprofundada dos artigos acadêmicos identificados. Diante da complexidade técnica e extensão das pesquisas analisadas, o NotebookLM serviu como ferramenta de apoio para esclarecer conceitos, detalhar metodologias e sintetizar conteúdos essenciais para embasar a nossa estratégia.

### Limitações e erros

Apesar da contribuição significativa, os modelos também apresentaram limitações. Durante a programação, erros ocasionais nos trechos de código sugeridos provocaram falhas de execução, exigindo ajustes e reiterações que consumiram tempo. Além disso, a própria “firma” simulada não apresentou desempenho perfeito, refletindo limitações inerentes tanto à disponibilidade de dados quanto à capacidade de raciocínio dos modelos. Ainda assim, os benefícios superaram os desafios, e os LLMs foram indispensáveis para o desenvolvimento do projeto.

### Reflexão final

A IA generativa mostrou-se como ferramenta fundamental para acelerar tarefas, principalmente de programação, tornando mais acessível essa área para aqueles que não dominam programação. Mais além, a nossa estratégia, e as pesquisas em que ela se baseou, mostram o potencial de uso lucrativo desses LLMs para negociação de ativos no mercado brasileiro.



## Bibliografia

- [1] HARTZMARK, Samuel M.; SOLOMON, David H. The dividend month premium. Los Angeles: University of Southern California, Marshall School of Business, Oct. 2012. Disponível em: <https://ssrn.com/abstract=1930620>
- [2] HARRIS, Lawrence E.; HARTZMARK, Samuel M.; SOLOMON, David H. Juicing the Dividend Yield: Mutual Funds and the Demand for Dividends. 2014. Working paper (SSRN n. 2510484). Disponível em: <https://ssrn.com/abstract=2510484>
- [3] HARTZMARK, Samuel M.; SOLOMON, David H. The Dividend Disconnect. 2018. Working paper (SSRN n. 2876373). Disponível em: <https://ssrn.com/abstract=2876373>
- [4] BOEHMER, Ekkehart; HUSZAR, Zsuzsa R.; JORDAN, Bradford D. The good news in short interest. *Journal of Financial Economics*, v. 96, n. 1, p. 80–97, 2010. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0304405X09002402>
- [5] WANG, Tianle; SHI, Haonan; LIU, Ziheng; DU, Yihong; ZHANG, Xiaoyang; LIU, Peng; ZHANG, Weinan. TradingAgents: a multi-agent LLM financial trading framework. [S.l.], 2023. Disponível em: <https://arxiv.org/abs/2412.20138>